



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위 논문

인프라 제한 없는 딥러닝 기반 실내
다층 측위 기법

Indoor multi-floor location
estimation technology based on
deep learning without
infrastructure constraints

2024년 12월

승실대학교 대학원

정보통신공학과

이 재 승

석사학위 논문

인프라 제한 없는 딥러닝 기반 실내
다층 측위 기법

Indoor multi-floor location
estimation technology based on
deep learning without
infrastructure constraints

2024년 12월

승실대학교 대학원

정보통신공학과

이 재 승

석사학위 논문

인프라 제한 없는 딥러닝 기반 실내
다층 측위 기법

지도교수 신 요 안

이 논문을 석사학위 논문으로 제출함

2024년 12월

숭실대학교 대학원

정보통신공학과

이 재 승

이 재 승 의 석 사 학 위 논 문 을 인 준 함

심 사 위 원 장 이 종 호 인

심 사 위 원 신 요 안 인

심 사 위 원 권 민 혜 인

2024년 12월

승실대학교 대학원

목 차

국문초록	v
영문초록	vii
제 1 장 서론	1
1.1 연구 배경 및 내용	1
1.2 논문의 구성	2
제 2 장 PDR 기법과 한계점	3
2.1 스마트폰 센서 기반 PDR 기법	3
2.2 PDR 기반 위치 측위 한계점	6
제 3 장 딥러닝 기반 다층 측위	8
3.1 딥러닝 기반 보폭추정 기법	9
3.2 기압데이터 기반 층 이동 감지	11
3.3 자기장 보정 노드 매칭 및 위치 보정	12
제 4 장 실험 및 결과	14
4.1 실험 환경과 성능지표	14
4.2 다층 측위 실험 결과	15
제 5 장 결론	18

참 고 문 헌	19
---------------	----

표 목 차

[표 4-1] 제안 기법과 일반 PDR 기법의 정확도 성능 지표	15
---	----

그 림 목 차

[그림 1-1] 스마트폰 기반 측위 종류	1
[그림 2-1] 보폭 추정과 누적 오차 그래프	7
[그림 3-1] 제안 기법의 플로우 차트	8
[그림 3-2] 보폭 추정 위한 MLP 모델 개요	9
[그림 3-3] 수집된 보행 경로 데이터	10
[그림 3-4] 실제 경로에 맞게 보정한 보행 경로 데이터	11
[그림 3-5] 층 이동 감지 Seq2Seq 모델 개요	12
[그림 3-6] 자기장 맵 기반 보정 노드 배치도	13
[그림 4-1] 층간 이동 감지 및 보행 상태 변화 그래프	16
[그림 4-2] 제안 모델의 최종 실험 결과	17

국문초록

인프라 제한 없는 딥러닝 기반 실내 다층 측위 기법

이재승

정보통신공학과

숭실대학교 대학원

실내 측위 기술은 GPS 신호의 한계를 극복하기 위한 대안으로 활발히 연구되고 있으며, 그중에서도 스마트폰 내장 센서를 활용한 PDR 기법은 추가적인 인프라 없이도 구현이 가능하고 에너지 소비가 적다는 점에서 주목받고 있다. 그러나 PDR은 사용자의 보행 패턴 및 경로의 다양성에 따라 누적 오차가 발생하며, 이로 인해 장기적인 위치 추정 정확도가 저하되는 한계가 있다. 이를 해결하기 위해 기존 연구에서는 Wi-Fi, BLE, UWB 등 외부 인프라를 활용한 접근법이 다수 제안되었으나, 이러한 방법은 설치와 유지보수에 높은 비용이 소모되며, 외부 시스템 의존성으로 인해 실용성에 제약이 있다. 이러한 문제를 보완하고자 본 논문에서는 외부 인프라 없이 스마트폰 내장 센서와 딥러닝 기술을 융합하여 실내 다층 환경에서도 높은 위치 추정 정확도를 제공할 수 있는 측위 기법을 제안한다. 제안 기법은 MLP 모델을 통해 평지 보행과 계단 보행 패턴을 분류하고, 건물 내부 자기장 데이터를 활용하여 보정 노드를 설치함으로써 위치 추정의 신뢰도를 향상시킨다. 또한, 기압계 데이터를 이용해 층

간 이동을 감지하고, 보정 노드와 연결하여 누적된 위치 오차를 보정하는 알고리즘을 구현하였다.

제안 기법은 기존 PDR 방식의 장점을 유지하면서 누적 오차 문제를 효과적으로 보완하였으며, 외부 인프라에 대한 의존성을 제거함으로써 유지보수 부담이 적고 실용성이 높은 실내 측위 솔루션의 가능성과 성능을 검증하였다.

ABSTRACT

Indoor multi-floor location estimation technology based on deep learning without infrastructure constraints

LEE, JAE-SEUNG

Department of Information & Telecommunication Eng.

Graduate School of Soongsil University

Indoor positioning technologies have been extensively studied as alternatives to overcome the limitations of GPS signals in indoor environments. Among these, PDR based on smartphone sensors has garnered attention due to its infrastructure-free implementation and low energy consumption. However, PDR suffers from cumulative errors caused by the variability in user walking patterns and trajectories, which degrade long-term positioning accuracy. To address this issue, previous studies have proposed approaches utilizing external infrastructures such as Wi-Fi, BLE, and UWB. While effective, these methods entail high installation and maintenance costs and impose practical constraints due to their reliance on external systems. To overcome these challenges, this

thesis proposes a localization method that combines smartphone sensors and deep learning technologies to achieve high positioning accuracy in multi-layer indoor environments without the need for external infrastructures. The proposed system utilizes an MLP model to classify walking patterns on flat surfaces and stairs, while leveraging magnetic field data from the building environment to deploy correction nodes, enhancing the reliability of position estimation. Additionally, barometric data is used to detect inter-floor movements, with an algorithm designed to correct accumulated positional errors when interacting with correction nodes.

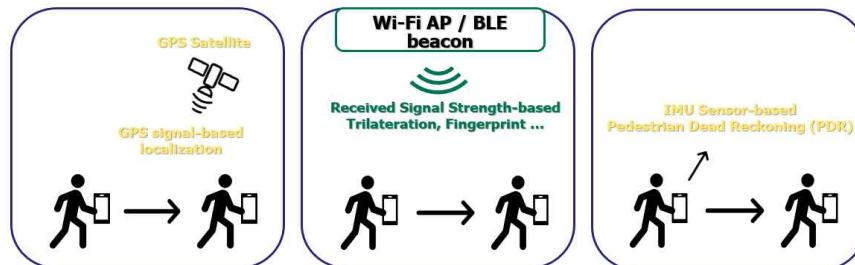
The proposed method retains the advantages of traditional PDR approaches while effectively mitigating cumulative error issues. By eliminating reliance on external infrastructures, it reduces maintenance costs and enhances practicality. The effectiveness and feasibility of the proposed infrastructure-independent indoor localization solution are validated, demonstrating its potential for reliable and scalable applications in various indoor environments.

제 1 장 서 론

1.1 연구 배경 및 내용

스마트폰 사용자의 실내 측위 (Indoor Localization) 기술은 [그림 1-1]과 같이 실외에서 주로 사용되는 GPS (Global Positioning System)와 실내에서 활용되는 무선 통신 신호, 그리고 스마트폰 내장 센서인 관성 측정 장치 (Inertial Measurement Unit: IMU)를 통한 보행자 관성 항법 (Pedestrian Dead Reckoning; PDR) 기법으로 구분할 수 있다. 무선 통신 신호 기반의 실내 측위는 경로 손실 (Path Loss), 섀도잉(Shadowing) 등과 같은 문제로 인해 정확도가 저하될 수 있으며, 재난 상황과 같은 비상 시에는 인프라의 손실로 인해 사용에 한계가 있다[1]-[4].

이러한 문제를 해결하기 위해, 최근에는 재난 상황 발생 시에도 정확한 구조 위치 파악이 가능하도록 외부 인프라에 의존하지 않는 고도화된 실내 측위 기술의 필요성이 대두되고 있다[5]-[8]. 이에 따라, 가속도 센서 (Accelerometer), 지자기 센서 (Magnetometer), 자이로스코프 (Gyroscope) 등을 포함한 스마트폰 내장 센서 기반의 PDR 기술이 주목받고 있으며, 다양한 센서 융합 기술들이 활발히 연구되고 있다. 이러한 기술들은 실내 측위의 정확성을 향상시키고, 재난 상황에서도 신뢰할 수 있는 위치 정보를 제공할 수 있는 가능성을 제시한다.



[그림 1-1] 스마트폰 기반 측위 종류

본 논문에서는 외부 인프라 활용 없이도 높은 정확도의 실내 위치 추정을 실현하기 위해 MLP (Multi-Layer Perceptron), Seq2Seq (Sequence-to-Sequence) 등의 딥러닝 모델을 활용하고, PDR 기법에 필요한 가속도 센서, 지자기 센서, 자이로스코프, 그리고 기압계 데이터를 융합하여 다층 실내 측위 방법을 제안한다. 제안하는 방법은 오직 스마트폰에 내장된 IMU 센서 데이터만을 융합하여 실내 다층 측위를 실현하는 것을 목표로 하며, 기존에 기압 데이터를 활용한 층 이동 감지 기술과 자기장 데이터를 활용한 위치 보정 기술들에 보폭 추정 기술을 연결하여 실내에서도 스마트폰만 있다면 설계, 구현까지 모두 가능한 측위 기술이다. 기존 PDR 기법에서 걸음 감지와 보폭 계산을 위한 가속도 센서 데이터를 MLP 모델을 통해 학습시켜 사용자의 보폭을 추정하고, 기압계 센서 데이터를 Seq2Seq 모델을 통해 학습하여 계단을 통한 층간 이동을 감지한다. 또한, 자기장 데이터를 활용한 보정 노드를 소프트웨어적으로 구현하여 매칭을 진행함으로써 실시간 위치 보정을 수행한다. 제안된 방법은 실제 숭실대학교 형남공학관 건물 내에서 스마트폰에 내장된 센서들만을 융합하여 실내 다층 측위를 실현하고, 그 성능을 검증하였다.

1.2 논문의 구성

본 논문의 구성은 다음과 같다. 2장에서는 PDR 기법과 한계점에 대해 소개하며, 3장에서는 스마트폰 센서의 활용과 제안하는 기법에 대해 기술한다. 4장에서는 센서 융합 딥러닝 기반 다층 측위 결과를 제시하며, 5장에서는 결론을 맺는다.

제 2 장 PDR 기법과 한계점

2.1 스마트폰 센서 기반 PDR 기법

본 장에서는 전통적인 PDR 기법의 위치 추적 과정을 다룬다. 스마트폰에 장착된 관성 측정 장치는 가속계(단위: m/s^2), 지자기 센서(단위: μT), 자이로스코프(단위: rad/s)로 구성되어 있으며, IMU 기반 PDR 기법은 사용자의 움직임에 따라 변화하는 이들 센서의 데이터를 활용하여 사용자의 이동을 감지하고, 걸음 길이 및 이동 방향을 계산하여 현재 위치를 추적한다.

먼저, 사용자의 걸음 감지와 보폭 계산에는 가속계 센서가 활용된다. 이 센서는 주변 환경이나 보행 경로의 영향을 받기보다는 사용자의 움직임에 의해 발생하는 진동에 따라 값이 변동한다. 이러한 측정 방식 덕분에 가속도 센서에서 발생하는 잡음의 변동은 상대적으로 적고, 다른 센서들에 비해 높은 신뢰성을 제공한다. 보행자의 위치 추적에 사용되는 이동 감지와 걸음 길이는 다음의 수식을 통해 계산된다[9].

$$A(t) = \sqrt{Acc_x^2(t) + Acc_y^2(t) + Acc_z^2(t)} \quad (1)$$

$$A(t) - g \geq Acc_{upper}, A(t + \Delta T) - g \leq Acc_{lower}, 0 < \Delta T < 1 \quad (2)$$

$$\lambda_{kim} = \tau_{kim} \cdot \left(\sum_{i=0}^N |A(i)| / N \right)^{\frac{1}{3}} \quad (3)$$

$$\lambda_{Weinberg} = \tau_{Weinberg} \cdot (A(\cdot)_{\max} - A(\cdot)_{\min})^{\frac{1}{4}} \quad (4)$$

여기서, $[Acc_i]_{i=x,y,z}$ 는 스마트폰 가속도 센서의 3축에서 측정된 값이며, Acc_{upper} 와 Acc_{lower} 는 이동 감지를 위한 상한 및 하한 값이다. 또한, $A(\cdot)$, $A(\cdot)_{\max}$, $A(\cdot)_{\min}$ 는 샘플링 (Sampling)된 가속도계 3축의 크기와

최대, 최소값을 나타낸다. 식 (3)과 (4)는 사용자의 보폭을 계산 하기 위해 사용되는 대표적인 기법으로, τ 의 설정에 따라 보폭 계산의 정확도가 결정된다[10]–[12].

스마트폰의 방향은 IMU 센서 데이터를 기반으로 지역 좌표계 (Local Coordinate System; LCS)에서 전역 좌표계 (Global Coordinate System; GCS)로 변환된다. 이 변환은 회전 행렬 (Rotation Matrix)을 사용하여 이루어지며, 방향 계산은 주로 가속도계와 지자기 센서를 결합한 방법과 자이로스코프 센서를 이용한 방법으로 나뉜다. 기본적으로 방향은 스마트폰 기준의 LCS에서 계산되며, 이를 지구 기준의 GCS(pitch, roll, yaw)로 변환하기 위해 다음과 같은 과정을 거친다. 먼저, IMU 가속계 센서에서 측정된 3축 가속도 값은 다음과 같이 표현된다.

$$a_{LCS} = \begin{bmatrix} a_x \\ a_y \\ a_z \end{bmatrix} \quad (5)$$

여기서 a_x, a_y, a_z 는 각각 x,y,z 방향의 가속도이다. 이 가속도 값은 중력 가속도 g 와 결합되어 GCS에서의 가속도 a_{GCS} 로 변환된다. 이 변환은 회전행렬 R_{PRY} 를 통해 이루어지며, 아래와 같이 표현된다.

$$a_{GCS} = R_{PRY} \begin{bmatrix} 0 \\ 0 \\ g \end{bmatrix} \quad (6)$$

P, R, Y는 각각 pitch, roll, yaw에 해당하는 회전각이고, 이 회전행렬은 특정 축에 대한 회전을 순차적으로 적용하여 최종적인 방향을 결정한다. 회전행렬은 다음과 같다.

$$R_{PRY} = R_P(\phi)R_R(\theta)R_Y(\psi) \quad (7)$$

각 회전 행렬은 특정 축에 대한 회전을 나타낸다.

- pitch 회전 행렬 $R_P(\phi)$ 는 x축을 기준으로 하는 회전하는 행렬
- roll 회전 행렬 $R_R(\theta)$ 는 y축을 기준으로 하는 회전하는 행렬

- yaw 회전 행렬 $R_Y(\psi)$ 는 z축을 기준으로 하는 회전하는 행렬

이러한 회전 행렬을 통해 가속계 센서의 값과 중력 가속도 g 를 결합하여 스마트폰의 방향을 정확하게 추정할 수 있다. 그러나 가속계 센서만으로는 yaw 각도(z축 기준 회전각)를 정확히 추정할 수 없기 때문에, 가속계와 지자기 센서의 데이터를 결합하여 yaw 각도를 계산한다. yaw 각도 a_{mag} 는 다음과 같이 계산한다.

$$a_{mag} = R_P(\phi)R_R(\theta)R_Y(\psi) \begin{bmatrix} 0 \\ 0 \\ H \end{bmatrix} \quad (8)$$

여기서 H 는 지구 자기력의 크기를 나타낸다. IMU 지자기 센서에서 측정한 값과 회전 행렬을 통해 yaw 각도를 추정할 수 있다. 최종적으로, 스마트폰의 3축 이동 방향은 다음과 같다.

$$d_{step} = \begin{bmatrix} \phi \\ \theta \\ \psi \end{bmatrix} \quad (9)$$

자이로스코프는 사용자의 회전을 감지하고 각속도를 측정하는 데 사용된다. 자이로스코프의 각속도 ω_{step} 는 코리올리 힘을 이용하여 측정되며, 이를 적분하여 스마트폰의 3축 회전각을 계산한다[13], [14].

$$F_{Coriolis} = 2m(\vec{v} \times \vec{\omega}) \quad (10)$$

$$\omega_{step} = \int \omega(t)dt \quad (11)$$

$F_{Coriolis}$ 에서 m 은 센서에 존재하는 물체의 질량, \vec{v} 는 물체의 속도, $\vec{\omega}$ 는 각속도를 의미한다.

$$\hat{L}_{step}(P_{step}, R_{step}) = \hat{L}_{step-1}(P_{step-1}, R_{step-1}) + \lambda_{step} \begin{bmatrix} \sin(\psi) \\ \cos(\psi) \end{bmatrix} \quad (12)$$

이때, 초기 방향은 가속계와 지자기 센서로 계산된 방향을 사용하여 설정한다. $step$ 번째에서 이동 방향과 보폭인 λ_{step} 가 계산된 후, 스마트폰 화면이 하늘을 향하고 있을 때 주요 회전축인 yaw 축의 방향을 사용하

여 사용자의 예측 위치를 식 (12)에 따라 결정한다.


2.2 PDR 기반 실내 측위 한계점

PDR 기법은 스마트폰에 내장된 가속도 센서와 자이로스코프를 활용하여 보행자의 이동 경로를 추적하는 방식으로, 추가적인 외부 인프라 없이 실내에서도 활용할 수 있는 장점이 있다. 그러나 해당 기법은 몇 가지 근본적인 한계점이 존재한다.

첫째, PDR 기법은 보폭과 이동 방향을 기반으로 사용자의 위치를 추정하는 방식이기 때문에, 사용자마다 다른 보행 패턴과 보폭으로 인해 오차가 발생한다. 보폭 추정 과정에서 사용자의 보행 특성이 반영되지 않으면 위치 추정 정확도가 낮아질 수 있다. 특히, 고정된 보폭 모델을 사용하는 경우, 실제 보행 속도와 변화하는 보폭을 정확히 반영하지 못해 장기적인 위치 추정에서 누적 오차가 증가하게 된다.

둘째, PDR 방식은 매 걸음마다 이동 방향과 거리를 계산하여 누적하는 방식으로 동작하므로, 계산 과정에서 발생하는 드리프트(Drift) 현상으로 인해 위치 추정에 대한 오차가 누적된다[15]. 이는 센서 데이터의 노이즈 및 시간 경과에 따른 오차 축적으로 이어지며, 장시간 경로 추적 시 위치 추정 결과의 신뢰도를 크게 저하시킨다. 특히 실내 환경과 같이 복잡한 구조에서, 작은 오차가 지속적으로 누적되어 실제 위치와 추정 위치 간의 차이가 커지게 된다.

[그림 2-1]은 이 두 가지 문제점을 시각화한 오차 그래프이다.



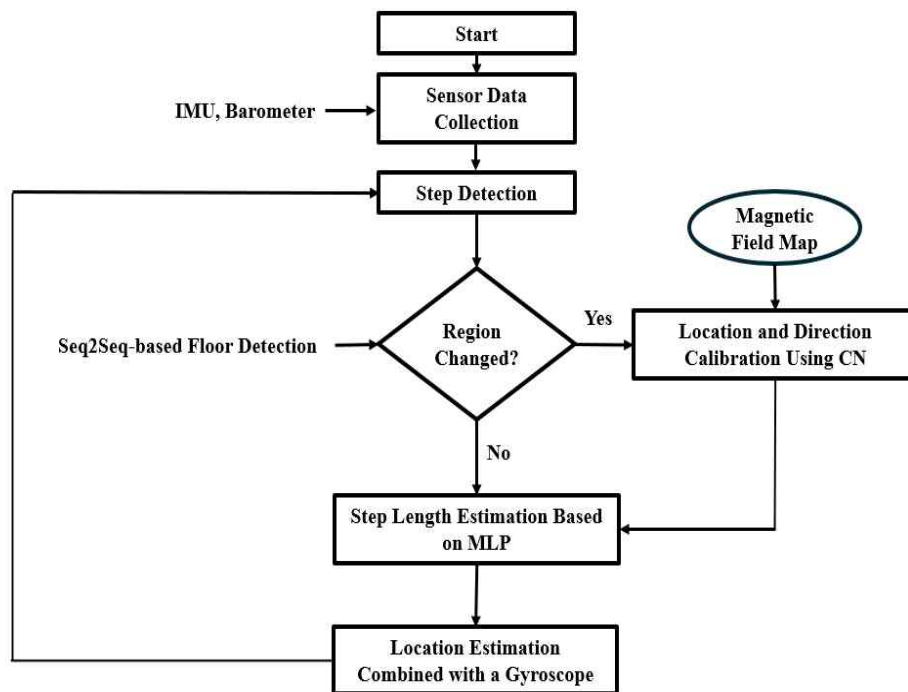
[그림 2-1] 보폭 추정과 누적 오차 그래프

셋째, PDR 기법은 보행자의 층간 이동을 인지하는 데 한계가 있다. 기압계 데이터가 없거나 제대로 활용되지 않을 경우, 수직 방향의 이동(예: 계단 또는 엘리베이터 이용)을 정확히 추적하지 못하며, 다층 구조를 갖는 실내 환경에서 위치 추정의 실효성이 떨어질 수 있다. 이러한 한계로 인해, 수직적 위치 정보의 부정확성은 실내 다층 환경에서 PDR의 활용성을 크게 제한한다.

결론적으로, PDR 기법은 외부 인프라 없이도 위치 추정이 가능하다는 장점이 있지만, 보폭 추정 문제, 드리프트 오차 누적, 다층 구조의 위치 추정 한계와 같은 문제를 보완해야만 실내 환경에서 신뢰도 높은 위치 추정이 가능하다. 이러한 한계점들을 해결하기 위해 딥러닝 기반의 보폭 추정, 자기장 데이터와의 융합, 기압계 활용을 토대로 제안 기법을 구현하였다.

제 3 장 딥러닝 기반 다층 측위

본 장에서는 제안하는 기법인 인프라 제한 없는 딥러닝 기반 다층 측위에 대한 프로세스를 다룬다. [그림 3-1]에서는 제안 기법의 흐름도를 도시하였고, 앞서 설명한 PDR 기법의 한계점 해결을 목적으로 설계하였다. 또한, 제안 기법의 동작 순서에 따라 사용자 보폭 추정, 층 이동 감지, 자기장 맵 기반 보정 노드 (Calibration Node; CN)를 활용한 위치 보정 방법에 대해 상세히 기술한다.




[그림 3-1] 제안 기법의 플로우 차트

3.1 딥러닝 기반 보폭 추정 기법

기본적인 PDR 기법의 경우 보폭을 계산하기 위해 사용자마다 알맞은 보정 계수를 설정하여 진행한다. 이는 사용자마다 신체적 차이점과 보행 습관에 따라 보폭은 모두 달라지기 때문이다[10]-[12]. 또한, 같은 사용자라 하더라도 일반적인 평지를 걷는 경우와 계단 등 상황에 따른 보폭은 변화하게 된다. 이를 해결하기 위해 MLP 모델을 사용하여 사용자의 평지 또는 계단에서의 보행 패턴이 바뀌는 것을 학습시켜 실내에서의 보행 경로에서 사용자에게 최적화된 보폭으로 위치 추적이 가능하게 설계하였다. 해당 기술은 외부 인프라를 활용하지 않고 실내에서 스마트폰을 통한 보행 데이터만을 사용하여 주심이 되는 PDR 기법의 성능 향상이 가능하다는 장점이 있다.

아래 [그림 3-2]은 보폭 추정을 위한 MLP 모델 구조이다.



[그림 3-2] 보폭 추정 위한 MLP 모델 개요


모델의 동작 과정은 다음과 같다. PDR 기법에서 보폭 계산에 필요한 가속도계 데이터의 최대, 최소값과 사용자의 보행 상태가 평지인지 계단인지 구분할 수 있도록 Flag를 입력값으로 사용한다.

본 연구에서는 보폭 예측과 같은 회귀 문제에 보편적이고 적합한 활성화 함수 ReLU (Rectified Linear Unit)와 손실함수 RMSE (Root Mean Squared Error)를 모델 하이퍼파라미터로 사용하였으며, 최적화 기법으로는 Adam Optimizer를 사용하였다. ReLU와 RMSE는 아래와 같이 계산된다.


$$ReLU(x) = \max(0, x) \quad (13)$$

$$RMSE = \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (14)$$

스마트폰 내장 센서를 통해 사용자가 보행하며 수집한 데이터를 토대로 일반적인 PDR을 진행하였을 때 실제 사용자의 보폭에 맞게 경로를 나타내려면 보정 계수를 매번 설정해야 한다. 이에 설계한 MLP 모델을 활용하여 [그림 3-3]를, [그림 3-4]과 같이 실제 보행 경로와 매핑시켜 학습을 진행하여 각 보행 상태에 따른 사용자의 보폭을 학습한다.




[그림 3-3] 수집된 보행 경로 데이터



[그림 3-4] 실제 경로에 맞게 보정한 보행 경로 데이터

3.2 기압 데이터 기반 층 이동 감지

건물 내 단층에서의 실내 측위만이 가능한 PDR 기법을 다층 측위가 가능하게 하도록 스마트폰에 내장된 기압계 (Barometer) 센서를 융합 활용하였다. 기압계 데이터 같은 경우 날씨 또는 부가 요소에 의해 같은 층에서도 시간에 따라 값의 변동이 잦다. 즉, 센서 자체가 민감하고 잡음이 많다는 것이다. 이에 각 층을 이동할 시 기압 값을 비교하는 것이 아닌 기압의 변화량을 비교하여 층간 이동을 감지하는 기존의 다층 측위 기술을 토대로, 앞서 소개한 보폭 추정 기법과 융합하기 위해 [그림 3-5]와 같은 Seq2Seq 모델을 변형 설계하였다.




[그림 3-5] 층 이동 감지 Seq2Seq 모델 개요

먼저 건물 내의 계단과 평지를 오가며 훈련데이터를 수집하여 진행하였다. 수집된 기압계 데이터를 전처리하기 위해, 각 데이터에서 평균값을 차감하여 데이터의 중심을 맞추는 후, 슬라이딩 윈도우 (Sliding Window) 기법을 적용하여 Seq2Seq 모델이 시계열 데이터의 패턴을 효과적으로 학습할 수 있도록 하였다[16], [17]. 이때 윈도우 크기는 15로 설정하였으며, 각 데이터에 대해 0과 1로 레이블링하여 분류하였다. 레이블 0은 Normal 상태, 레이블 1은 Stairs 상태로 나타낸다. 15개의 기압 차이를 입력으로 받아 사용자의 현재 상태를 예측하도록 설계되었다. 이때 분류된 레이블은 앞서 설명한 보폭 추정 MLP 모델의 입력값으로 들어가 사용자의 보행 상태를 구분하는 데에 사용되기 때문에 위아래 이동을 구분짓지 않고 평지 상태와 계단 상태만을 구분하는 2개의 레이블로 설정하여 구현하였다.

3.3 자기장 맵 기반 보정 노드 매칭 및 위치 보정

앞서 언급한 두 모델을 통해 사용자의 보행 상태에 따른 보폭 추정과 다층 측위를 위한 층 이동 감지는 해결하였지만, 사용자의 회전 방향에 따른 누적 드리프트 오차에 대해서는 아직 극복하지 못하였다.

본 장에서는 각 층의 이동 수단에 설정된 보정 노드를 활용하여 사용자의 위치를 보정함으로써 PDR 기법에서 발생하는 위치 추정 정확도 감소 문제를 해결하였다. 제안된 보정 노드는 기존의 단순 보정 노드와 달리, 자기장 데이터를 추가로 활용하여 보정 노드 집합을 자기장 맵으로 구성하였다. 이 보정 노드에는 자기장 데이터, 이동 방향, 위치, 층 정보가 포함되어 있다.



[그림 3-6] 자기장 맵 기반 보정 노드 배치도

[그림 3-6]은 사전에 수집된 자기장 맵의 구성을 나타낸다. 사용자가 스마트폰에서 실시간 위치 측정 애플리케이션을 실행하고 딥러닝 모델이 층 이동을 감지하면, 해당 층의 자기장 맵에 포함된 보정 노드 중에서 사용자의 지자기 센서 값과 가장 유사한 노드가 선택된다. 유사도는 유클리드 거리 (Euclidean Distance) 계산을 통해 측정된다[16], [18], [19].

이와 같은 보정 과정은 기존 PDR 기법의 드리프트 문제를 효과적으로 완화하며, 실내 환경에서도 높은 위치 추정 정확도를 제공할 수 있도록 설계되었다.

제 4 장 실험 및 결과

본 4장에서는 제안한 보폭 추정, 층 이동 감지 모델들을 활용한 종합적인 다층 실내 측위 실험 결과를 제시한다.

4.1 실험 환경과 성능지표

본 실험은 스마트폰 사용자의 보행 데이터를 확보하기 위해 Android OS에서 데이터 수집 프로그램을 구축하였고 스마트폰 삼성 Galaxy S8을 실험기기로 사용하여 데이터 수집 및 실험을 진행하였다. 또한, 제안 기법에서 사용된 MLP, Seq2Seq 모델 등을 훈련하기 위해 Python의 TensorFlow 라이브러리를 활용하였고 NVIDIA GeForce RTX 4080 GPU를 컴퓨터 자원으로 활용하였다.

실험 경로에 따라 수집된 센서 데이터를 활용하여 기존의 전통적인 PDR 기법과 제안된 딥러닝 기반 다층 측위 모델의 위치 추정 정확도를 비교하기 위해, 성능지표로 평균 제곱 오차(Mean Square Error, MSE)와 정확도 비율(Accuracy Rate, AR)을 사용한다.

$$MSE = \frac{1}{N} \sum_{k=1}^N (P_k - \hat{P}_k)^2 \quad (15)$$

식 (15)는 MSE 수식을 나타내며, 실제 위치 지점 $P(x, y)$ 와 예측 위치 지점 $\hat{P}(x, y)$ 간의 차이의 제곱을 계산한 후, 이를 전체 측위 개수 N 로 나누어 예측 지점에서 발생하는 평균적인 오류를 정량적으로 나타낸다.

$$\epsilon_k = \sqrt{(P_k - \hat{P}_k)^2} \text{ if } \epsilon_k \leq N \quad (16)$$

$$AR = \frac{N}{\sum_k I(\epsilon_k \leq \epsilon)} \cdot 100\% \quad (17)$$

식 (16), 식 (17)은 AR 수식을 나타내며, 실제 위치 지점을 기준으로

설정된 오차 범위 ϵ 내에 예측 지점이 포함되는지를 평가하여 측위 정확도를 다음과 같이 정의한다.

[표 4-1]은 제안 기법인 인프라 제한 없는 딥러닝 기반 실내 다층 측위 모델과 일반 PDR 기법의 정확도를 나타내는 성능지표로 높은 측위 성능을 확인하였다.


	AR =0.5m	AR =1.0m	AR =1.5m	AR =2.0m	RMSE [m]
Proposed scheme	44.81%	74.81%	97.03%	98.88%	0.79
PDR	24.81%	25.18%	26.66%	30%	3.72

[표 4-1] 제안 기법과 일반 PDR 기법의 정확도 성능 지표

4.2 다층 측위 실험 결과


최종 실험은 숭실대학교 형남공학관 건물에서 진행하였다. 형남공학관 5층 중간 복도에서 출발하여 계단을 통해 2개 층을 내려가 3층 복도를 지나 강의실을 들어갔다 나오며 보행 경로를 설정하였다. 약 270걸음 정도의 보행 데이터가 발생하였고, 테스트 데이터로써 제안 모델과 실제 경로를 비교하여 성능을 확인하였다.

[그림 4-1]은 Seq2Seq 층 이동 감지 모델의 결과로 기압계 데이터를 통해 얻은 값을 시각화 하여 사용자가 층간 이동 시 보행 상태 변화 예측 성능을 검증하였다.



[그림 4-1] 층간 이동 감지 및 보행 상태 변화 그래프

[그림 4-2]은 최종 실험을 위한 테스트 데이터의 결과를 나타내는 제안 모델의 예측 결과이다. 앞서 언급한 실제 보행 경로는 빨간색으로 표시되어 있고, 제안 모델을 통한 PDR 결과는 파란색으로 표시되어있다. 실제 경로와 대조해봤을 때 정확도 높은 측위 성능을 확인할 수 있다. 또한, 층 이동 후 해당 층의 정보까지 확인하여 다층 측위의 성능을 검증하였다.



[그림 4-2] 제안 모델의 최종 실험 결과

제 5 장 결론

본 논문에서는 기본적인 PDR 기법에서 발생하는 문제점들을 보완하
되, 외부 인프라를 활용하지 않고 독립적인 스마트폰 내장 센서 융합 딥
러닝 기반 다층 실내 측위 기법을 제안하기 위해 중심이 되는 PDR 기
법의 보폭 추정 기술에 기존의 기압 데이터를 이용한 다층 측위 기술과
자기장 데이터를 이용한 위치 보정 기술을 응용하여 구현하였다. 이를
위해 MLP와 Seq2Seq 모델을 사용하여 필요로 하는 센서 데이터들을
학습시키고, 자기장 보정 노드를 매칭해 실내 다층 측위를 구현하였다.

본 논문의 주된 결과들은 다음과 같다. 첫째, MLP 모델을 활용하여
사용자의 보폭 계산에 필요한 가속도계 데이터를 학습시켜 실제 경로와
매핑해 사용자의 상황별 보폭을 예측하였다. 둘째, Seq2Seq 모델을 활용
하여 기압계 데이터를 학습시켜 계단을 통한 층 이동이 감지되도록 구현
하였다. 셋째, 층 이동 감지 시 배치해놓은 자기장 보정 노드를 통해 위
치를 보정하여 누적 오차를 해결하였다.

실험 결과, 사용된 MLP와 Seq2Seq 모델은 높은 예측 성능으로 사용
자의 이동 경로에 대한 적절한 보폭과 층 이동을 예측함에 있어 성공적
임을 확인하였다. 실제 숭실대학교 형남공학관 건물내에서 실험한 결과,
목표로 했던 재난 상황같은 유사시에 활용이 가능한 외부 인프라 제한이
없는 실내 다층 측위 기술이 높은 성능을 보였다.

참고 문헌

- [1] H. Liu, H. Darabi, P. Banerjee, and J. Liu, "Survey of wireless indoor positioning techniques and systems," *in IEEE Trans. Syst. Man Cybern. C Appl. Rev.*, vol. 37, no. 6, pp. 1067–1080, Nov. 2007.
- [2] N. Kim and Y. Kim, "A novel RSS-ratio position estimation scheme for Wi-Fi networks," *Proc. ICEEM 2015, Phuket, Thailand*, pp. 61–64, Dec. 2015.
- [3] J. Zuo, S. Liu, H. Xia, and Y. Qiao, "Multi-phase fingerprint map based on interpolation for indoor localization using iBeacons," *in IEEE Sensors Jour.*, vol. 18, no. 8, pp. 3351–3359, Apr. 2018.
- [4] A. Zayets, C. Gentner, and E. Steinbach, "High-Precision Multipath-Based Indoor Localization Scheme With User Privacy Protection for Dynamic NLoS Environments," *in IEEE Access*, vol. 9, pp. 116033–116049, Aug. 2021.
- [5] S. Subedi, D.-H. Kim, B.-H. Kim, and J.-Y. Pyun, "Improved Smartphone-Based Indoor Localization System Using Lightweight Fingerprinting and Inertial Sensors," *in IEEE Access*, vol. 9, pp. 53343–53357, Apr. 2021.
- [6] R. Elbakly, H. Aly, and M. Youssef, "TrueStory: Accurate and robust RF-based floor estimation for challenging indoor environments," *in IEEE Sensors Jour.*, vol. 18, no. 24, pp. 10115–10124, Dec. 2018.
- [7] P. Li, X. Yang, Y. Yin, S. Gao, and Q. Niu, "Smartphone-Based

- Indoor Localization With Integrated Fingerprint Signal,” in *IEEE Access*, vol. 8, pp. 33178–33187, Feb. 2020
- [8] T. L. N. Nguyen, T. D. Vy, K.-S. Kim, C. Lin, and Y. Shin, “Smartphone-Based Indoor Tracking in Multiple-Floor Scenarios,” in *IEEE Access*, vol. 9, pp. 141048–141063, Oct. 2021.
- [9] S. Traini, L. Sciullo, A. Trotta, and M. Di Felice, “Practical indoor localization via smartphone sensor data fusion techniques: A performance study” *Proc. IEEE CCNC 2019*, pp. 1–7, Las Vegas, USA, Feb. 2019.
- [10] J. W. Kim, H. J. Jang, D. H. Hwang, and C. Park, “A step, stride and heading determination for the pedestrian navigation system,” in *Jour. Global Positioning Syst.*, vol. 3, no. 1–2, pp. 273–279, 2004.
- [11] H. Weinberg, “AN-602: Using the ADXL202 in pedometer and personal navigation applications,” Analog Devices Tech. Rep., 2002. [Online]. Available: http://www.analog.com/static/importedfiles/application_notes/513772624AN602.pdf.
- [12] J. Scarlet, “Enhancing the performance of pedometers using a single accelerometer,” Analog Devices Tech. Rep., 2007. [Online]. Available: http://www.sgbotic.com/products/appnotes/sensors/4707-6299220991AN_900.pdf
- [13] V. Marotto, A. Serra, D. Carbouni, M. Sole, T. Dessi, and A. Manchinu, “Orientation analysis through a gyroscope sensor for

- indoor navigation systems,” *Proc. IFSA Sensordevice 2013*, Barcelona, Spain, pp. 85–90, Aug. 2013.
- [14] A. D. King, “Inertial navigation - Forty years of evolution,” *GEC Review*, vol. 13, no. 3, pp. 140–149, 1998.
- [15] D. Piyabongkarn, R. Rajamani, and M. Greminger, “The development of a MEMS gyroscope for absolute angle measurement,” in *IEEE Trans. Control Syst. Technol.*, vol. 13, no. 2, pp. 185–195, Mar. 2005.
- [16] C. Lin and Y. Shin, “Multi-floor indoor localization scheme using a Seq2Seq-based floor detection and particle filter with clustering,” in *IEEE Access*, vol. 11, no. 1, pp. 66094–66112, Jun. 2023.
- [17] C. Yi, W. Choi, Y. Jeon, and L. Liu, “Pressure-pair-based floor localization system using barometric sensors on smartphones,” *Sensors*, vol. 19, no. 16, pp. 3622–3640, Aug. 2019.
- [18] C. Lin and Y. Shin, “Deep learning-based direction estimation scheme using smartphone inertial sensors,” *J. KICS*, vol. 47, no. 6, pp. 898–907, Jun. 2022.
- [19] J. Kim, and Y. Shin, “Indoor Multi-Floor Localization Based on Location Calibration Combined with Magnetic Maps and Deep Learning Models,” *J. KICS*, vol. 49, no. 10, pp. 1354–1357, Oct. 2024.